

Banco de Dados e Engenharia de Dados

Aula 11 - Big Data, Engenharia de Dados, Pipelines, Análise de Dados e Arquitetura Moderna de Dados

Campo	Detalhe
Disciplina	Banco de Dados e Engenharia de Dados - 8 questões no edital
Banca	FGV - Fundação Getulio Vargas
Recorte da aula	Noções de Big Data e análise de dados; pipelines; arquitetura moderna de dados; dados estruturados, semiestruturados e não estruturados; processamento batch e streaming; qualidade, metadados e linhagem.
Objetivo	Transformar termos modernos de dados em acerto objetivo, sem deslocar o eixo principal do edital para NoSQL ou ciência de dados avançada.
Padrão	Material autoral, calibrado por provas públicas da FGV e por referências técnicas oficiais. Questões inéditas; nenhuma questão real copiada.

Recorte exato da aula

Esta aula cobre a Aula 11 da trilha: Big Data, engenharia de dados, pipelines, análise de dados e arquitetura moderna de dados. No edital do TJSC, o item diretamente atingido é “Noções de Big Data e análise de dados”, conectado aos itens já estudados de OLTP, OLAP, SQL, Data Warehouse, Data Mart, ETL, ELT e BI.

1. Direcionamento FGV e escopo de prova

A FGV, em provas recentes de tecnologia e dados, tem cobrado Big Data de forma aplicada: não basta saber que há grande volume de dados; é preciso reconhecer arquitetura, fluxo, camada, finalidade e consequência operacional. O padrão mais provável para o TJSC é um cenário com logs, processos, documentos, relatórios, painéis, APIs, trilhas de auditoria, eventos ou arquivos heterogêneos, seguido de alternativas com termos próximos.

O ponto de maior retorno é separar quatro planos que a banca costuma embaralhar: armazenamento, processamento, orquestração e consumo analítico. Hadoop, Spark, Kafka, Airflow, Data Lake, Lakehouse, Data Warehouse, Data Mart, ETL, ELT e BI não são sinônimos. Cada um ocupa papel diferente no ecossistema de dados.

Pegadinha matriz da aula

Big Data não é apenas “muitos dados”. É um conjunto de problemas de volume, velocidade, variedade, veracidade e valor que pode exigir arquitetura distribuída, pipelines confiáveis, governança, qualidade e processamento em lote ou em fluxo.

1.1 Índice sintético

Bloco	Conteúdo	Como pode cair na FGV
1	Big Data e os 5 Vs	Distinguir volume, velocidade, variedade, veracidade e valor em cenários.
2	Tipos de dados	Estruturados, semiestruturados e não estruturados.
3	Engenharia de dados	Pipelines, ingestão, transformação, armazenamento e disponibilização.
4	Batch e streaming	Escolha de arquitetura para relatórios, logs e eventos em tempo real.
5	Hadoop, Spark, Kafka e Airflow	Papel de cada tecnologia sem confundir ferramenta de processamento com orquestrador.
6	Data Lake, Lakehouse e arquitetura em camadas	Bronze, Silver, Gold; schema-on-read; schema enforcement; camada analítica.
7	Qualidade, metadados e linhagem	Dimensões de qualidade, catálogo, lineage, rastreabilidade e auditoria.
8	Análise de dados	Análise descritiva, diagnóstica, preditiva e prescritiva no nível de noções.
9	20 questões autorais	Treino com formatos variados e comentários completos.

2. Big Data: conceito real e 5 Vs

Big Data é o campo que trata a **captura, armazenamento, processamento, governança e análise de conjuntos de dados cujo volume, velocidade, variedade ou complexidade tornam inadequadas as soluções tradicionais isoladas**. A FGV pode apresentar Big Data como problema técnico e organizacional: logs de sistemas, arquivos, mensagens, documentos, transações, registros de acesso, trilhas de auditoria, eventos de APIs e dados analíticos.

Os “5 Vs” são uma forma clássica de organizar o conceito:

V	Significado	Exemplo em sistema corporativo
Volume	Quantidade de dados a armazenar e processar.	Milhões de movimentações processuais, documentos, logs e registros de acesso.
Velocidade	Ritmo de geração, ingestão e processamento.	Eventos de audiência, notificações, logs de segurança ou uso de API chegando continuamente.
Variedade	Diversidade de formatos e estruturas.	Tabelas relacionais, JSON, CSV, XML, PDF, texto, imagem, log e mensagem.
Veracidade	Confiabilidade, qualidade e incerteza dos dados.	Duplicidade, inconsistência de CPF, timestamp inválido, dado incompleto.
Valor	Capacidade de gerar decisão, automação, controle ou insight.	Painel de produtividade, detecção de gargalos, previsão de demanda, auditoria.

Cuidado FGV

Se a alternativa reduzir Big Data a armazenamento barato, ou disser que Big Data dispensa qualidade, modelagem, governança e metadados, ela tende a estar errada. Dados volumosos sem valor, sem qualidade e sem rastreabilidade viram passivo técnico.

3. Estruturado, semiestruturado e não estruturado

A engenharia de dados lida com diferentes formatos. A diferença principal não é o arquivo estar em banco ou fora dele, mas o grau de estrutura explícita que permite consulta e validação.

Tipo	Descrição	Exemplos	Pegadinha
Estruturado	Segue esquema rígido, colunas e tipos bem definidos.	Tabelas SQL, planilhas tabulares bem modeladas, fatos e dimensões.	Não é sinônimo de dado correto; pode estar estruturado e ruim.
Semiestruturado	Possui marcação ou estrutura flexível, mas não necessariamente tabela fixa.	JSON, XML, logs com campos, mensagens de eventos.	Não significa ausência total de estrutura.
Não estruturado	Não segue esquema tabular facilmente extraível.	PDF, áudio, imagem, texto livre, vídeos.	Pode ser catalogado e enriquecido com metadados.

Em sistemas com APIs REST - Representational State Transfer -, o formato JSON aparece muito. Para prova, JSON costuma ser exemplo de dado semiestruturado: há chaves e valores, mas o esquema pode variar entre mensagens, versões e produtores.

4. Engenharia de dados: função e fronteiras

Engenharia de dados é a disciplina que constrói e opera pipelines para coletar, ingerir, transformar, validar, armazenar, documentar e disponibilizar dados para uso analítico, operacional ou científico. Diferentemente do analista de BI, que consome e modela indicadores, o engenheiro de dados se preocupa com fluxo, confiabilidade, escalabilidade, custo, versionamento, observabilidade e reprocessamento.

Atividade	Pergunta de prova	Exemplo
Ingestão	Como os dados entram na plataforma?	Carga de tabelas Oracle, leitura de arquivos CSV, consumo de tópico Kafka, captura de CDC.
Transformação	Como dados brutos viram dados úteis?	Padronizar datas, tratar nulos, deduplicar, enriquecer, agregar.
Orquestração	Qual tarefa roda antes de qual?	DAG no Airflow com dependência entre extração, validação e publicação.
Qualidade	O dado é confiável para consumo?	Checagem de completude, unicidade, consistência e validade.
Observabilidade	Como detectar falha e degradação?	Logs, métricas, alertas, lineage, SLA, tempo de execução.
Disponibilização	Como consumidores acessam o dado?	Tabela Gold, Data Mart, API, consulta SQL, painel de BI.

Ligação com sua prática

Em Java/Quarkus e APIs, você já pensa em contrato, idempotência, logs, integração e versionamento. Em engenharia de dados, a mesma mentalidade aparece em pipelines: contrato de dados, reprocessamento seguro, schema evolution, observabilidade e impacto downstream.

5. Pipeline de dados

Pipeline de dados é uma sequência controlada de etapas que movimenta e transforma dados de fontes para destinos. Pode ser simples, como extrair uma tabela e carregar em um Data Mart, ou complexo, como consumir eventos em tempo real, enriquecer com dimensões, validar qualidade, gravar em lakehouse e publicar métricas.

Fontes -> Ingestão -> Zona bruta -> Tratamento -> Validação -> Camada analítica -> Consumo
 APIs Batch Bronze Silver Qualidade Gold/Data Mart BI/SQL/ML
 Logs Streaming Raw files Padronização Lineage Dimensional Painéis
 OLTP CDC Landing Enriquecim. Alertas Features APIs

5.1 Propriedades de um bom pipeline

- Idempotência: executar novamente não deve duplicar ou corromper o resultado.
- Reprocessabilidade: deve ser possível recomputar dados de uma janela ou camada quando a regra muda.
- Observabilidade: logs, métricas, alertas e rastreabilidade de falhas.
- Controle de dependências: uma etapa deve esperar as entradas necessárias.
- Validação de qualidade: checar schema, nulos, duplicidade, domínio, referencialidade e frescor.
- Versionamento: código, esquema, regras de transformação e, quando possível, dados ou snapshots.
- Segurança: controle de acesso, mascaramento, segregação de dados sensíveis e trilha de auditoria.

Pegadinha FGV

Orquestrar pipeline não é o mesmo que processar dados. O Airflow agenda e coordena tarefas; o processamento pesado pode ocorrer em Spark, SQL engine, dbt, Python, procedure, serviço de nuvem ou outro executor.

6. Batch, streaming e micro-batch

O processamento em lote - batch - trabalha com conjuntos acumulados em janelas: diária, horária, mensal ou sob demanda. O streaming processa eventos continuamente, à medida que chegam. O micro-batch é uma estratégia intermediária: processa pequenos lotes frequentes, simulando baixa latência.

Modo	Quando usar	Vantagem	Limite/pegadinha
Batch	Fechamento diário, relatório mensal, consolidação histórica.	Simplicidade, menor custo, fácil reproprocessamento.	Não atende bem a decisões que exigem reação imediata.
Streaming	Alertas, monitoramento, eventos de auditoria, detecção em tempo quase real.	Baixa latência e reação contínua.	Complexidade maior: ordem, duplicidade, janela, tolerância a falhas.
Micro-batch	Atualizações frequentes com simplicidade relativa.	Compromisso entre latência e robustez.	Não é evento a evento puro; ainda há pequena janela.

Em prova, o erro comum é escolher streaming apenas porque o volume é alto. Volume alto pode ser tratado por batch distribuído. Streaming se justifica quando a latência e a reação contínua são requisitos relevantes.

7. Ecossistema: Hadoop, Spark, Kafka e Airflow

A FGV gosta de apresentar nomes de ferramentas e trocar seus papéis. O essencial é associar cada tecnologia ao problema que resolve.

Tecnologia	Papel principal	Não confundir com
Hadoop	Framework para armazenamento e processamento distribuído em clusters; historicamente associado ao HDFS - Hadoop Distributed File System - e MapReduce.	SGBD relacional, ferramenta de BI ou orquestrador de DAGs.
Spark	Engine unificada de processamento distribuído para grandes volumes, com SQL, batch, streaming, MLlib e APIs em várias linguagens.	Banco de dados transacional ou simples fila de mensagens.
Kafka	Plataforma de streaming de eventos, baseada em tópicos, produtores, consumidores, partições e offsets.	Ferramenta de ETL visual ou banco analítico dimensional.
Airflow	Orquestrador de workflows/pipelines como DAGs - Directed Acyclic Graphs. Agenda, monitora e coordena tarefas.	Engine de processamento distribuído ou armazenamento de dados.

7.1 Kafka em prova: produtor, consumidor, tópico, partição e offset

Em Kafka, produtores publicam eventos em tópicos; consumidores leem eventos desses tópicos; **partições permitem paralelismo** e **ordenação por partição**; offsets registram posição de leitura. O uso típico em engenharia de dados é ingestão de eventos, integração assíncrona, CDC e pipelines near real-time.

7.2 Spark em prova: engine, não banco

Spark executa processamento distribuído. Pode consultar dados com Spark SQL e processar dados estruturados, semiestruturados e streaming estruturado. Isso não o torna um SGBD OLTP. A confusão “Spark = banco de dados” é um distrator provável.

8. Data Lake, Lakehouse e arquitetura em camadas

Um Data Lake armazena grandes volumes de dados em diferentes formatos, muitas vezes em armazenamento barato e escalável, com menor rigidez inicial de esquema. Um Data Warehouse é mais estruturado, orientado a análise e normalmente usa esquema definido antes da carga. O Lakehouse tenta combinar flexibilidade de lake com confiabilidade e governança próximas ao warehouse, usando formatos de tabela e camadas de qualidade.

Arquitetura	Ideia central	Ponto forte	Risco/limite
Data Warehouse	Dados integrados, modelados e governados para análise.	BI, consistência, desempenho analítico, SQL.	Menos flexível para dados brutos heterogêneos.
Data Lake	Armazenamento amplo de dados brutos e variados.	Flexibilidade, baixo custo, dados semiestruturados/não estruturados.	Pode virar data swamp se faltar catálogo, qualidade e governança.
Lakehouse	Lake com camada de tabela, metadados, transações e governança para análise.	Une batch/streaming, ACID em formatos modernos, camadas Bronze/Silver/Gold.	Não elimina necessidade de modelagem, qualidade e controle de acesso.

8.1 Arquitetura medalhão

A arquitetura medalhão organiza dados em camadas progressivas de qualidade. A nomenclatura varia por plataforma, mas a ideia é estável:

Camada	Função	Exemplo
Bronze	Dados brutos ou quase brutos, preservando origem e histórico.	Arquivos de log, eventos de API, cópia inicial de tabela OLTP.
Silver	Dados limpos, padronizados, deduplicados, com regras técnicas aplicadas.	Datas padronizadas, chaves harmonizadas, registros inválidos tratados.
Gold	Dados de negócio, agregados, dimensionais ou prontos para consumo.	Indicadores por comarca, unidade, classe processual e período.

FGV pode explorar

Bronze não é “dado errado”; é dado bruto. Silver não é painel final; é camada tratada. Gold não é necessariamente melhor tecnicamente em tudo; é a camada mais próxima do consumo de negócio, BI, relatórios, métricas e modelos.

9. Schema-on-write, schema-on-read e schema enforcement

Schema-on-write significa aplicar estrutura antes ou durante a escrita. É típico de Data Warehouse e bancos relacionais: os dados precisam obedecer ao esquema para entrar. Schema-on-read significa armazenar dados primeiro e interpretar o esquema na leitura; é comum em Data Lake.

Lakehouses modernos reduzem o caos do schema-on-read puro ao usar formatos de tabela com metadados, controle de versão, transações, schema enforcement e schema evolution. A FGV pode apresentar Delta Lake, Apache Iceberg ou Apache Hudi como mecanismos que adicionam confiabilidade de tabela a dados em lake. O edital do TJSC não exige decorar cada feature, mas exige entender a finalidade arquitetural.

10. Qualidade de dados

Qualidade de dados é adequação ao uso. Na prova, qualidade não é apenas “dado sem erro de digitação”; envolve dimensões mensuráveis e controles durante o pipeline.

Dimensão	Pergunta	Exemplo de regra
Acurácia	O dado representa corretamente a realidade?	Valor de pagamento igual ao registrado no sistema de origem.
Compleitude	Há dados obrigatórios ausentes?	Todo processo deve ter classe, unidade e data de distribuição.
Consistência	O dado não contradiz outro dado?	Data de baixa não pode ser anterior à distribuição.
Pontualidade/atualidade	O dado chegou no tempo necessário?	Painel diário atualizado até 7h.
Validade	O dado obedece formato, domínio e regra?	UF com duas letras válidas; CPF com formato esperado.
Unicidade	Há duplicidade indevida?	Mesmo evento não deve ser gravado duas vezes.

10.1 Data quality gates

Data quality gates são pontos de validação no pipeline. Uma carga pode ser bloqueada, isolada, alertada ou marcada como suspeita se violar regra crítica. A FGV pode perguntar qual medida reduz risco de publicar indicador incorreto: resposta provável envolve validação, quarentena, metadados e lineage, não apenas aumentar cluster.

11. Metadados, catálogo e linhagem

Metadados são dados sobre dados. Eles descrevem origem, significado, estrutura, tipo, qualidade, sensibilidade, dono, frequência de atualização e uso. Catálogo de dados organiza esses metadados para descoberta e governança. Linhagem - lineage - mostra o caminho do dado: de onde veio, por quais transformações passou e quais consumidores são impactados.

Elemento	Serve para	Exemplo de prova
Metadado técnico	Descrever estrutura, tipo, partição, schema, timestamp, job.	Coluna data_evento é TIMESTAMP; tabela atualiza diariamente.
Metadado de negócio	Descrever significado e regra de uso.	“Processo baixado” conforme regra X do tribunal.
Catálogo	Permitir descoberta, classificação, dono e documentação.	Analista encontra dataset oficial de movimentações processuais.
Linhagem	Rastrear origem, transformações e impacto.	Erro em tabela origem afeta painel e indicador publicado.
Data owner/steward	Responsabilidade e curadoria.	Unidade responsável valida conceito de indicador.

12. Arquiteturas modernas: Lambda, Kappa, DataOps e Data Mesh

Alguns termos modernos aparecem em provas recentes, mas no TJSC devem ser estudados com foco conceitual e de reconhecimento, sem desviar do edital.

Termo	Ideia	Pegadinha
Lambda Architecture	Combina camada batch, camada de velocidade/streaming e camada de serviço.	Não é apenas “usar Lambda da AWS”; é padrão arquitetural de dados.
Kappa Architecture	Simplifica usando fluxo de eventos como fonte principal, reduzindo duplicidade batch+speed.	Não serve magicamente para todo cenário histórico; reprocessamento exige log/eventos retidos.
DataOps	Aplicação de práticas de automação, versionamento, testes, monitoramento e colaboração a pipelines de dados.	Não é ferramenta única; é prática operacional.
Data Mesh	Abordagem organizacional: dados como produto, orientados a domínio, com governança federada.	Não é substituto direto de Data Lake ou Spark.

ROI para TJSC

Decore o papel, não detalhes de vendor. A FGV tende a cobrar “qual arquitetura ou prática se encaixa no cenário?”. Não gaste energia tentando memorizar comandos de Hadoop, Kafka ou Spark nesta disciplina.

13. Análise de dados: do dado ao insight

No edital, “análise de dados” tende a ser cobrada em nível de noções. A classificação mais útil separa análise descritiva, diagnóstica, preditiva e prescritiva.

Tipo	Pergunta respondida	Exemplo TJSC
Descritiva	O que aconteceu?	Quantidade de processos distribuídos por comarca no mês.
Diagnóstica	Por que aconteceu?	Causa do aumento de filas em uma unidade.
Preditiva	O que tende a acontecer?	Previsão de demanda por classe processual.
Prescritiva	O que fazer?	Recomendar alocação de servidores para reduzir gargalos.

Em BI, a análise descritiva e diagnóstica costuma ser dominante. Em ciência de dados e IA, análises preditivas e prescritivas aparecem mais. Mas a engenharia de dados é o alicerce: sem pipeline confiável, qualidade, metadados e dados disponíveis, o modelo ou painel pode apenas automatizar erro.

14. Checklist final de memorização

- Big Data = problema de volume, velocidade, variedade, veracidade e valor; não apenas base grande.
- Pipeline = fluxo controlado de ingestão, transformação, validação, armazenamento e disponibilização.
- Batch = lote; streaming = eventos contínuos; micro-batch = lotes pequenos e frequentes.
- Hadoop = processamento/armazenamento distribuído clássico; HDFS e MapReduce são termos-chave.
- Spark = engine distribuída unificada; suporta SQL, batch, streaming e MLlib, mas não é SGBD OLTP.
- Kafka = plataforma de eventos; tópicos, partições, produtores, consumidores e offsets.
- Airflow = orquestra workflows como DAGs; não é engine de processamento de dados.
- Data Lake = flexível e bruto; Data Warehouse = modelado e governado; Lakehouse = lake com recursos de tabela e governança.
- Bronze = bruto; Silver = limpo/padronizado; Gold = pronto para consumo de negócio.
- Qualidade = acurácia, completude, consistência, atualidade, validade e unicidade.
- Metadados e linhagem permitem descoberta, auditoria, rastreabilidade e análise de impacto.
- DataOps = práticas de engenharia para pipelines; Data Mesh = abordagem organizacional por domínio.

15. Lista de questões autorais - padrão FGV

Resolva as 20 questões antes de consultar o gabarito. As questões são autorais e foram elaboradas para simular densidade, vocabulário e armadilhas plausíveis da FGV, sem copiar enunciados reais.

Questão 1

No contexto de um projeto de análise de dados do tribunal, uma equipe passou a coletar registros de movimentações processuais, logs de acesso, documentos em PDF, mensagens JSON de APIs e eventos de auditoria. O problema técnico não está restrito ao tamanho dos arquivos, mas também à diversidade de formatos, à taxa de geração e à confiabilidade dos registros. Essa descrição se aproxima mais diretamente do conceito de:

- A) normalização relacional, pois a existência de dados em múltiplos formatos implica violação da Primeira Forma Normal.
- B) Big Data, pois envolve volume, velocidade, variedade e veracidade como dimensões relevantes do problema de dados.
- C) OLTP, pois todo dado gerado por sistema transacional deve ser tratado apenas em banco relacional normalizado.
- D) modelo estrela, pois logs, PDFs e eventos devem ser convertidos diretamente em dimensões e fatos.
- E) índice bitmap, pois a diversidade de dados é resolvida pela criação de estruturas de acesso físico.

Questão 2

Considere as afirmativas sobre Big Data e análise de dados. I. Volume é a única dimensão necessária para caracterizar Big Data. II. Variedade envolve a coexistência de dados estruturados, semiestruturados e não estruturados. III. Valor indica que o dado deve ser capaz de apoiar decisão, controle, automação ou insight. Está correto o que se afirma em:

- A) I, apenas.
- B) I e II, apenas.
- C) II e III, apenas.
- D) I e III, apenas.
- E) I, II e III.

Questão 3

Em uma arquitetura de dados, arquivos brutos de sistemas de origem são inicialmente armazenados sem grande transformação; depois passam por padronização, deduplicação e validações; por fim, são disponibilizados em tabelas agregadas para painéis de BI. Na arquitetura medalhão, essas etapas correspondem, respectivamente, a:

- A) Gold, Silver e Bronze.
- B) Silver, Bronze e Gold.
- C) Bronze, Silver e Gold.
- D) Bronze, Gold e Silver.
- E) Silver, Gold e Bronze.

Questão 4

Relacione as tecnologias aos papéis mais adequados. 1. Apache Kafka. 2. Apache Airflow. 3. Apache Spark. 4. Hadoop/HDFS. () Plataforma para eventos, tópicos, produtores, consumidores, partições e offsets. () Orquestração de workflows como DAGs. () Engine distribuída para processamento de dados em larga escala. () Sistema/ecossistema associado a armazenamento distribuído em blocos e processamento em clusters. A sequência correta é:

- A) 1 - 2 - 3 - 4.
- B) 2 - 1 - 3 - 4.
- C) 1 - 3 - 2 - 4.
- D) 4 - 2 - 3 - 1.
- E) 3 - 2 - 1 - 4.

Questão 5

Um pipeline diário carrega dados de processos de um banco transacional para uma camada analítica. Em uma falha, o job é reexecutado para o mesmo período e passa a duplicar registros na tabela de destino. A propriedade de engenharia de dados que deveria ter sido melhor tratada é:

- A) idempotência.
- B) cardinalidade máxima.

- C) dependência transitiva.
- D) particionamento horizontal obrigatório.
- E) normalização para FNBC.

Questão 6

Um analista afirma que o Apache Airflow é adequado para executar, ele próprio, o processamento distribuído de grandes volumes de dados, substituindo Spark ou SQL engines, pois DAG é o mecanismo físico de processamento paralelo de dados. A afirmação está:

- A) correta, pois Airflow é um SGBD analítico otimizado para consultas colunares.
- B) correta, pois DAGs eliminam a necessidade de engine de processamento.
- C) incorreta, pois Airflow é voltado à autoria, agendamento e monitoramento de workflows, podendo acionar outras ferramentas para processar dados.
- D) incorreta apenas porque Airflow só executa cargas OLTP síncronas.
- E) correta, desde que todos os dados estejam em formato JSON.

Questão 7

Sobre processamento em lote e em fluxo contínuo, assinale a alternativa correta.

- A) Streaming é obrigatório sempre que o volume de dados supera a capacidade de um único servidor.
- B) Batch é inadequado para dados históricos, pois só processa eventos em tempo real.
- C) Micro-batch é sinônimo de processamento manual, sem automação.
- D) Streaming tende a ser adequado quando a latência de decisão é requisito relevante, como em alertas ou monitoramento contínuo.
- E) Batch e streaming são equivalentes, diferenciando-se apenas pelo formato do arquivo de entrada.

Questão 8

Em uma plataforma de dados, a equipe deseja saber quais painéis e tabelas serão afetados se a coluna `data_baixa` de uma tabela de origem for alterada. O recurso mais diretamente associado a essa análise de impacto é:

- A) linhagem de dados.
- B) índice clusterizado.
- C) chave substituta.
- D) partição de tópico Kafka.
- E) terceira forma normal.

Questão 9

Considere uma tabela de controle de qualidade de uma carga de dados: campo `processo_id`: 0 nulos; campo `comarca`: 14% nulos; campo `data_distribuicao`: 3% de valores futuros inválidos; campo `numero_processo`: 2% duplicados. A alternativa que associa corretamente os problemas é:

- A) `comarca`: unicidade; `data_distribuicao`: completude; `numero_processo`: acurácia.
- B) `comarca`: completude; `data_distribuicao`: validade; `numero_processo`: unicidade.
- C) `comarca`: validade; `data_distribuicao`: linhagem; `numero_processo`: atualidade.
- D) `comarca`: veracidade; `data_distribuicao`: cardinalidade; `numero_processo`: integridade física.
- E) `comarca`: normalização; `data_distribuicao`: snowflake; `numero_processo`: streaming.

Questão 10

Em relação a Data Lake, Data Warehouse e Lakehouse, assinale a opção correta.

- A) Data Lake é sempre mais governado que Data Warehouse, pois dispensa catálogo e modelagem.
- B) Data Warehouse é voltado a dados modelados e integrados para análise, enquanto Data Lake tende a armazenar dados variados e brutos com maior flexibilidade.
- C) Lakehouse é apenas outro nome para banco OLTP relacional.
- D) Data Warehouse e Data Lake são equivalentes quando ambos armazenam arquivos CSV.
- E) Data Lake impede o uso de dados semiestruturados, por exigir schema-on-write estrito.

Questão 11

No contexto de engenharia de dados, CDC - Change Data Capture - é mais bem descrito como:

- A) técnica de captura de mudanças ocorridas em uma fonte de dados para propagação a outro sistema ou pipeline.
- B) algoritmo de classificação supervisionada usado para prever rótulos em dados históricos.
- C) modelo dimensional usado para representar fatos sem medidas.

- D) restrição SQL que impede duplicidade de chave primária.
- E) formato de tabela que substitui a necessidade de metadados.

Questão 12

Um órgão deseja processar continuamente eventos de acesso a sistemas, preservando a ordem por usuário sempre que possível e permitindo consumo paralelo. Em Kafka, uma decisão usual para esse tipo de necessidade é:

- A) usar partições e uma chave de particionamento coerente, como `id_usuario`, entendendo que a ordenação é garantida por partição.
- B) usar apenas um arquivo CSV diário, pois Kafka não trabalha com eventos.
- C) desativar offsets, pois consumidores não precisam controlar posição de leitura.
- D) usar chave estrangeira para garantir ordenação global entre todos os tópicos.
- E) substituir tópicos por views materializadas em banco OLTP.

Questão 13

Uma questão apresenta as seguintes camadas: batch layer, speed layer e serving layer. A arquitetura de dados associada a essa combinação é:

- A) Kappa Architecture.
- B) Lambda Architecture.
- C) Data Mesh.
- D) Star Schema.
- E) Two-phase commit.

Questão 14

Assinale a alternativa que melhor expressa a diferença entre schema-on-write e schema-on-read.

- A) Schema-on-write aplica a estrutura antes ou durante a gravação; schema-on-read interpreta a estrutura no momento da leitura.
- B) Schema-on-write só existe em bancos NoSQL; schema-on-read só existe em bancos relacionais.
- C) Schema-on-write significa ausência de validação; schema-on-read significa chave primária obrigatória.
- D) Schema-on-write é uma técnica de visualização; schema-on-read é uma operação OLAP.
- E) Schema-on-write e schema-on-read são nomes de índices físicos usados pelo SQL Server.

Questão 15

Em uma organização pública, cada área de negócio passa a tratar seus conjuntos de dados como produtos, com responsáveis de domínio, contratos de qualidade e governança federada. Essa descrição se aproxima mais de:

- A) Data Mesh.
- B) FNBC.
- C) índice bitmap.
- D) replicação síncrona de banco OLTP.
- E) modelo entidade-relacionamento clássico.

Questão 16

Sobre Apache Spark, analise as afirmativas. I. É uma engine unificada para processamento de dados em larga escala. II. Pode apoiar processamento SQL, batch, streaming e aprendizado de máquina, dependendo dos módulos usados. III. É, por definição, um SGBD OLTP relacional destinado a substituir PostgreSQL e Oracle em transações bancárias. Está correto o que se afirma em:

- A) I, apenas.
- B) II, apenas.
- C) I e II, apenas.
- D) II e III, apenas.
- E) I, II e III.

Questão 17

Em um lakehouse, formatos de tabela como Delta Lake ou Apache Iceberg são citados em provas recentes porque tendem a acrescentar aos data lakes recursos como:

- A) ausência obrigatória de metadados, para acelerar leitura direta de arquivos brutos.
- B) transações, metadados, evolução de esquema e maior confiabilidade para tabelas analíticas.
- C) eliminação de qualquer necessidade de qualidade de dados e de governança.

- D) armazenamento exclusivo em linhas normalizadas de terceira forma normal.
- E) substituição de todos os painéis de BI por filas de mensagens.

Questão 18

Um pipeline falha quando recebe mensagens duplicadas de um produtor. A equipe decide usar chave natural do evento, controle de offset, deduplicação e escrita idempotente na camada Silver. A medida está principalmente associada a:

- A) aumentar a granularidade dimensional do cubo OLAP.
- B) garantir que reprocessamentos e duplicidades não publiquem resultados incorretos.
- C) converter streaming em modelagem conceitual.
- D) apagar a camada Bronze para reduzir histórico.
- E) trocar análise descritiva por análise prescritiva.

Questão 19

A análise que responde “o que aconteceu”, como total de processos distribuídos por comarca e mês, é classificada primariamente como:

- A) prescritiva.
- B) diagnóstica.
- C) descritiva.
- D) preditiva.
- E) cognitiva autônoma.

Questão 20

Assinale a alternativa INCORRETA sobre Big Data e arquitetura moderna de dados.

- A) A camada Gold costuma estar mais próxima do consumo de negócio, BI e indicadores.
- B) Metadados e catálogo ajudam descoberta, governança e compreensão dos dados disponíveis.
- C) Data swamp é risco de um Data Lake sem governança, qualidade e organização.
- D) Streaming elimina automaticamente duplicidade, atraso, reprocessamento e problemas de ordenação.
- E) Pipelines de dados devem ser observáveis, reprocessáveis e testáveis, especialmente em contexto corporativo.

16. Gabarito resumido

1-B | 2-C | 3-C | 4-A | 5-A | 6-C | 7-D | 8-A | 9-B | 10-B | 11-A | 12-A | 13-B | 14-A | 15-A | 16-C | 17-B | 18-B | 19-C | 20-D

Observação: o gabarito foi construído de forma orgânica, sem quota fixa de letras, e revisado para evitar padrão visual artificial.

17. Comentários completos

Questão 1 - Gabarito: B

A alternativa correta é B. O cenário envolve múltiplas dimensões clássicas de Big Data: dados volumosos, diversos, gerados em ritmo elevado e com necessidade de avaliar confiança e valor.

- A) Confunde variedade de dados com problema de 1FN. Normalização relacional pode ser relevante depois, mas não define o fenômeno descrito.
- B) Correta. Volume, velocidade, variedade e veracidade aparecem no caso; valor surge no uso analítico e de controle.
- C) OLTP é processamento transacional; não resolve sozinho logs, PDFs e eventos heterogêneos para análise.
- D) Modelo estrela pode ser camada Gold/BI, mas não é a descrição geral do problema.
- E) Índice é decisão física de acesso; não resolve diversidade e governança de dados.

Questão 2 - Gabarito: C

A alternativa correta é C. Big Data não se reduz a volume; variedade e valor são dimensões essenciais no raciocínio moderno de dados.

- A) Errada porque I é falsa: volume sozinho não basta.
- B) Errada porque inclui I, falsa.
- C) Correta: II e III traduzem dimensões clássicas e úteis para prova.
- D) Errada porque inclui I e omite II.
- E) Errada porque I torna o conjunto incorreto.

Questão 3 - Gabarito: C

A alternativa correta é C. Na arquitetura medalhão, Bronze preserva dados brutos, Silver limpa e padroniza, Gold entrega dados prontos para consumo de negócio.

- A) Inverte a ordem, colocando Gold como camada bruta.
- B) Coloca Silver antes de Bronze, erro comum quando se pensa apenas em qualidade.
- C) Correta: Bronze -> Silver -> Gold.
- D) Troca Silver e Gold; Gold não é etapa intermediária técnica.
- E) Também inverte a progressão natural de qualidade.

Questão 4 - Gabarito: A

A alternativa correta é A. Kafka é eventos; Airflow é DAG/orquestração; Spark é processamento distribuído; Hadoop/HDFS é ecossistema de armazenamento/processamento distribuído clássico.

- A) Correta. Associa cada tecnologia ao papel típico.
- B) Troca Kafka e Airflow.
- C) Troca Airflow e Spark.
- D) Começa com Hadoop para eventos, inadequado.
- E) Coloca Spark como plataforma de eventos e Kafka como engine principal de processamento.

Questão 5 - Gabarito: A

A alternativa correta é A. Idempotência é a propriedade de permitir reexecução sem duplicar ou corromper o resultado.

- A) Correta. Reprocessamento seguro depende de escrita idempotente, chaves e deduplicação.
- B) Cardinalidade máxima pertence a modelagem de relacionamentos.
- C) Dependência transitiva é tema de normalização, não falha de reexecução.
- D) Particionamento pode ajudar desempenho, mas não garante ausência de duplicidade.
- E) FNBC não resolve por si só duplicação causada por reprocessamento.

Questão 6 - Gabarito: C

A alternativa correta é C. Airflow orquestra tarefas, mas não é a engine principal de processamento distribuído de dados.

- A) Errada: Airflow não é SGBD analítico.
- B) Errada: DAG coordena dependências; não elimina engine de execução.
- C) Correta. Airflow agenda, monitora e coordena workflows.
- D) Errada porque restringe Airflow a OLTP, o que não faz sentido.
- E) Errada: formato JSON não transforma Airflow em engine de Big Data.

Questão 7 - Gabarito: D

A alternativa correta é D. Streaming é apropriado quando a latência da decisão importa e há fluxo contínuo de eventos.

- A) Volume alto pode ser tratado por batch distribuído; streaming não é obrigatório por volume.
- B) Batch é justamente muito usado para histórico e janelas consolidadas.
- C) Micro-batch é técnica automatizada, não processamento manual.
- D) Correta. Alertas e monitoramento contínuo justificam streaming.
- E) A diferença não é só formato de entrada; envolve modelo temporal e latência.

Questão 8 - Gabarito: A

A alternativa correta é A. Linhagem permite rastrear origem, transformação e impacto downstream.

- A) Correta. Lineage responde quem consome e o que será afetado.
- B) Índice acelera acesso, não mostra impacto semântico.
- C) Chave substituta identifica dimensão, não rastreia fluxo.
- D) Partição Kafka ajuda paralelismo/ordenação em tópico.
- E) 3FN trata dependência transitiva em tabelas relacionais.

Questão 9 - Gabarito: B

A alternativa correta é B. Nulos em comarca indicam completude; datas futuras inválidas indicam validade; números duplicados indicam unicidade.

- A) Troca completude por unicidade e validade por completude.
- B) Correta. Associa cada problema à dimensão de qualidade mais direta.
- C) Linhagem não é validação de data; atualidade não é duplicidade.
- D) Mistura termos genéricos e modelagem com qualidade de dados.
- E) Normalização, snowflake e streaming são conceitos de outra camada.

Questão 10 - Gabarito: B

A alternativa correta é B. Data Warehouse é mais modelado e governado para análise; Data Lake é flexível para dados variados e brutos.

- A) Data Lake sem catálogo e governança pode virar data swamp.
- B) Correta. Resume a distinção mais provável em prova.
- C) Lakehouse não é banco OLTP relacional.
- D) Mesmo usando CSV, arquitetura e finalidade continuam diferentes.
- E) Data Lake é adequado justamente a variedade, inclusive semiestruturados.

Questão 11 - Gabarito: A

A alternativa correta é A. CDC captura alterações em fontes de dados e as propaga para pipelines, integrações ou camadas analíticas.

- A) Correta. Change Data Capture significa captura de mudanças.
- B) Classificação supervisionada é tema de ciência de dados, não CDC.
- C) Fato sem medida é modelagem dimensional, não CDC.
- D) Restrição SQL de chave é integridade relacional.
- E) Formato de tabela não elimina metadados.

Questão 12 - Gabarito: A

A alternativa correta é A. Em Kafka, partições permitem paralelismo, e uma chave coerente ajuda a preservar ordem dentro da partição.

- A) Correta. A ordenação é por partição; chave de particionamento afeta distribuição.
- B) Kafka trabalha com eventos; CSV diário é padrão batch distinto.

- C) Offsets são centrais para controle de leitura.
- D) Chave estrangeira pertence ao modelo relacional, não ordenação em tópicos.
- E) Views materializadas não substituem o papel de tópico de eventos.

Questão 13 - Gabarito: B

A alternativa correta é B. Batch layer, speed layer e serving layer são componentes associados à Lambda Architecture.

- A) Kappa simplifica ao usar fluxo/event log como base principal.
- B) Correta. É a decomposição clássica da arquitetura Lambda.
- C) Data Mesh é abordagem organizacional por domínios.
- D) Star schema é modelagem dimensional.
- E) Two-phase commit é protocolo transacional distribuído.

Questão 14 - Gabarito: A

A alternativa correta é A. Schema-on-write valida/aplica estrutura antes ou durante a escrita; schema-on-read interpreta o dado ao consultar.

- A) Correta. É a distinção essencial para warehouse/lake.
- B) Ambos podem aparecer em arquiteturas variadas; não há exclusividade absoluta.
- C) Inverte a lógica e associa conceitos incorretos.
- D) Não são operação OLAP nem visualização.
- E) Não são índices físicos do SQL Server.

Questão 15 - Gabarito: A

A alternativa correta é A. Data Mesh trata dados como produtos orientados a domínio, com responsabilidades distribuídas e governança federada.

- A) Correta. O cenário descreve claramente Data Mesh.
- B) FNBC é forma normal relacional.
- C) Índice bitmap é estrutura de acesso físico.
- D) Replicação síncrona é alta disponibilidade, não organização por domínio.
- E) MER é modelagem conceitual de entidades e relacionamentos.

Questão 16 - Gabarito: C

A alternativa correta é C. Spark é engine de processamento em larga escala e possui módulos para SQL, batch, streaming e ML; não é SGBD OLTP transacional.

- A) Errada porque II também é verdadeira.
- B) Errada porque I também é verdadeira.
- C) Correta. I e II descrevem bem o papel do Spark.
- D) Errada porque III é falsa.
- E) Errada porque III é falsa.

Questão 17 - Gabarito: B

A alternativa correta é B. Formatos como Delta Lake e Iceberg acrescentam camada de tabela, metadados, transações, evolução de esquema e maior confiabilidade a lakes.

- A) Errada: esses formatos usam metadados, não ausência deles.
- B) Correta. É a finalidade arquitetural cobrável.
- C) Errada: governança e qualidade continuam necessárias.
- D) Errada: não exigem exclusivamente 3FN em linhas normalizadas.
- E) Errada: não substituem BI por mensageria.

Questão 18 - Gabarito: B

A alternativa correta é B. Chaves de evento, controle de offset, deduplicação e escrita idempotente mitigam duplicidade e falhas de reprocessamento.

- A) Granularidade dimensional não é o problema central.
- B) Correta. A medida protege consistência do resultado publicado.
- C) Streaming não vira modelagem conceitual por deduplicação.
- D) Apagar Bronze prejudica rastreabilidade e reprocessamento.
- E) Tipo de análise não resolve duplicidade operacional.

Questão 19 - Gabarito: C

A alternativa correta é C. Análise descritiva responde “o que aconteceu”.

- A) Prescritiva recomenda ações.
- B) Diagnóstica busca causas.
- C) Correta. Contagem por comarca e mês descreve fatos passados.
- D) Preditiva estima futuro.
- E) Cognitiva autônoma não é classificação clássica cobrável aqui.

Questão 20 - Gabarito: D

A alternativa correta é D, pois a questão pede a INCORRETA. Streaming não elimina automaticamente duplicidade, atraso, reprocessamento ou ordenação; esses problemas exigem desenho cuidadoso.

- A) Verdadeira. Gold é camada próxima do consumo de negócio.
- B) Verdadeira. Catálogo e metadados apoiam descoberta e governança.
- C) Verdadeira. Data swamp é risco de lake sem organização.
- D) Incorreta. Streaming aumenta a necessidade de lidar com duplicidade, atraso, janela e ordenação.
- E) Verdadeira. Observabilidade, reprocessamento e testes são práticas essenciais.

18. Referências consultadas

- TJSC - Edital n. 10/2026, retificado em 10/04/2026: conteúdo de Banco de Dados e Engenharia de Dados.
- Manual Mestre de Calibração FGV para Aulas e Questões - Projeto TJSC 2026.
- FGV Conhecimento - provas e editais públicos de tecnologia, arquitetura de dados, ciência de dados e Big Data, usados apenas para calibrar estilo, densidade, vocabulário e formato.
- Apache Hadoop - documentação oficial: processamento distribuído de grandes conjuntos de dados em clusters.
- Apache Spark - documentação oficial: engine unificada para processamento de dados em larga escala, SQL, streaming e MLlib.
- Apache Kafka - documentação oficial: plataforma de event streaming com tópicos, produtores e consumidores.
- Apache Airflow - documentação oficial: autoria, agendamento e monitoramento de workflows como DAGs.
- Microsoft Learn / Azure Databricks - arquitetura medalhão: camadas Bronze, Silver e Gold.
- Delta Lake - documentação oficial: lakehouse com transações ACID, metadados escaláveis e unificação batch/streaming.
- Apache Iceberg - documentação oficial: open table format para grandes tabelas analíticas.
- IBM e DAMA - dimensões de qualidade de dados: acurácia, completude, consistência, atualidade, unicidade e validade.